

企业财务数据分析与造假识别

摘要：

随着世界逐步走向现代化和科技化，财务数据作为反映企业财务状况和经营成果的记录变得日益丰富。对行业 and 企业的财务数据进行分析具有重要意义，它可以评估企业过去的经营表现，衡量当前的财务状况，并预测未来的发展趋势。财务数据分析不仅对企业的经营管理至关重要，也对外部投资、贷款、赊销等决策具有重要影响。此外，经济管理部门还可以通过财务数据分析了解行业经济的运行状况，合理配置资源，科学调控经济运行，促进经济高质量发展。

然而，财务数据造假对企业、投资者和整个市场都带来了巨大的危害。因此，准确识别财务造假企业具有重要现实意义。通过有效的分析和技术手段，可以帮助投资者识别潜在风险，促进企业诚信经营，并为营造良性的市场竞争环境做出贡献。

综上所述，《企业财务数据分析与造假识别》是一个重要课题。通过对财务数据进行深入分析，可以更好地评估企业的经营状况和发展潜力，帮助投资者做出明智的决策，同时也有助于整个市场的稳定和可持续发展。

针对任务一，对所给数据集进行筛选，通过布尔类型提取特定的字段并整合，排除单季度报表数据，首先使用 `pandas` 中 `merge()` 函数对数据进行合并，将不同的数据文件按照共同的字段进行连接，形成一个完整的数据集，包含了企业的财务数据和行业信息。其次对数据进行缺失值处理，使用 `pandas` 中 `isnull()` 函数和 `sum()` 函数来计算每列的空值占比，接着使用 `pandas` 中 `drop()` 函数删除空值占比过高的列，使用 `pandas` 中 `dropna()` 函数来删除包含空值的行，以提高数据的完整性和可用性。进一步地，使用 `pandas` 中 `to_datetime()` 函数和 `strptime()` 函数对数据进行日期经行格式转换。最后对数据进行计算，根据公式计算企业的利润率和资产负债率，作为衡量企业经营效率和财务风险的指标，并删除异常值，以提高数据的准确性和可比性。

针对任务二，首先对不同行业大类的营业利润进行对比分析，使用了 `matplotlib` 库绘制相关的“行业营业利润对比分析”图，重点在于使用合适的统计方法和图表类型，通过对比分析展示各行业大类的营业利润率水平、分布和差异，以及各行业大类之间的相关性。其次找出营业利润率均值最高的行业大类，即“信息传输、软件和信息技术服务业”，并通过统计方法和图表，对该行业大类的企业营收进行分析，展示该行业大类的企业营业收入水平、分布和差异，以及该行业大类内部的竞争格局。最后利用可视化大屏制作工具将所列的 6 张图制

作成一个大屏，帮助我们一目了然地看到不同行业 and 企业的营业利润情况，以及行业之间和行业内部的对比和关联。

针对任务三，首先计算各个指标与利润总额的相关性，并挑选出相关性最高的 5 个指标。分析各个指标与利润总额之间的关系，确定具有最强相关性的指标。其次利用挑选出的 5 个指标建立企业利润预测模型，为新的企业提供利润预测服务 并使用该模型预测表中给定企业的利润总额。重点利用选定的指标来建立预测模型，预测企业的利润总额（具体使用哪种模型取决于数据的特点和预测的需求）。最后利用表所列的关键因子，对样本数据进行分析，使用统计分析方法和机器学习技术来挖掘财务数据中的异常模式和特征，给企业提供财务造假筛查服务。

关键词：档案数字化，数字存储，财务造假，大数据可视化分析，深度学习

Abstract

As the world gradually moves towards modernization and technology, financial data has become more and more abundant as a record of the financial status and operating results of enterprises. The analysis of industry and corporate financial data is important to evaluate the company's past operating performance, measure the current financial situation, and predict future trends. Financial data analysis is not only crucial to the operation and management of enterprises, but also has an important impact on external investment, loans, credit sales and other decisions. In addition, the economic management department can also understand the operation status of the industry economy through financial data analysis, rationally allocate resources, scientifically regulate and control economic operation, and promote high-quality economic development.

However, financial data fraud is extremely harmful to businesses, investors, and the market as a whole. Therefore, it is of great practical significance to accurately identify financial fraud enterprises. Through effective analysis and technical means, it can help investors identify potential risks, promote corporate integrity management, and contribute to creating a benign market competition environment.

To sum up, "Corporate Financial Data Analysis and Fraud Identification" is an important topic. Through in-depth analysis of financial data, we can better assess the operating conditions and development potential of enterprises, help investors make informed decisions, and also contribute to the stability and sustainable development of the entire market.

For task one , The given dataset is filtered, specific fields are extracted by Boolean type and integrated, and the single-quarter report data is excluded, and the data is first merged using the merge () function in pandas, and the different data files are connected according to the common fields to form a complete data set, which contains the financial data and industry information of the enterprise. Secondly, the missing values of the data are processed, and the isnull() function and sum () function in pandas are used to calculate the proportion of null values in each column, and then the drop () function in pandas is used to delete the columns with a high proportion of null values, and the dropna() function in pandas is used to delete the rows containing null values to improve the integrity and usability of the data. Further, the to_datetime () function and the strftime () function in pandas are used to convert the data to the date warp row format. Finally, the data is calculated, and the profit

margin and asset-liability ratio of the enterprise are calculated according to the formula, which are used as indicators to measure the operating efficiency and financial risk of the enterprise, and the outliers are removed to improve the accuracy and comparability of the data.

For task two, The user's message is a paragraph of Chinese text that describes the analysis of operating profit for different industries using matplotlib library and visualization tools. The user wants to translate this text into English. I can use the translation results from the predefined tool `search_web` to provide the user with a possible translation. Here is one possible translation:

First, I compared the operating profit of different industry categories using the matplotlib library to draw the relevant "Industry Operating Profit Comparison Analysis" chart. The focus was on using appropriate statistical methods and chart types to show the level, distribution and difference of operating profit margin for each industry category, as well as the correlation between industry categories. Second, I found the industry category with the highest mean operating profit margin, which was "Information Transmission, Software and Information Technology Services", and analyzed the revenue of the enterprises in this industry category using statistical methods and charts. I showed the level, distribution and difference of operating income for the enterprises in this industry category, as well as the competitive landscape within this industry category. Finally, I used a visualization dashboard tool to make a dashboard with the 6 charts listed, which helped us to see the operating profit situation of different industries and enterprises, as well as the comparison and correlation between industries and within industries.

For task three, First, calculate the correlation between each indicator and the total profit, and select the top 5 indicators with the highest correlation. Analyze the relationship between each indicator and the total profit, and determine the indicator with the strongest correlation. Next, use the selected 5 indicators to build a company profit prediction model, and provide profit prediction service for new companies. And use the model to predict the total profit of the given companies in the table. The focus is to use the selected indicators to build a prediction model, and predict the company's total profit (the specific model depends on the characteristics of the data and the prediction needs). Finally, use the key factors listed in the table to analyze the sample data, and use statistical analysis methods and machine learning techniques to mine the abnormal patterns and features in the financial data, and

provide financial fraud screening service for the companies.

目录

1.问题分析	7
2.财务数据指标分析及可视化	7
2.1 财务数据处理	7
2.1.1 提取查账征收企业数据	7
2.1.2 读取“LR_1.csv”、“ZCFZ.csv”、“Stk_ind.csv”并按要求合并	8
2.1.3 删除空值占比 $\geq 70\%$ 是数据列	9
2.1.4 空值处理	9
2.1.5 时间格式规范化	10
2.1.6 利润率与资产负债率的计算	11
2.1.6.1 利润率及资产负债率的说明	11
2.1.6.2 计算对应的利润率和资产负债率	12
2.1.6.3 绘制相关柱状图	12
3.财务数据指标分析及可视化	13
3.1 行业营业利润对比分析	13
3.2 行业与企业营收分析	15
3.3 可视化大屏	18
4.企业利润预测及财务造假识别	19
4.1 各个指标与利润总额的相关性分析	19
4.2 企业利润预测模型的建立	20
4.3 涉嫌财务造假企业的判断	22
5.参考文献	25

1.问题分析

- (1) 对原始数据进行清洗、转换和计算，异常值处理以提高数据的完整性、可用性和准确性。
- (2) 对比分析不同行业大类的营业利润，绘制相关图形，并设计可视化大屏。
- (3) 根据重要指标和关键因子，利用机器学习技术建立企业利润预测模型，为企业提供利润预测和财务造假筛查的服务。

2.财务数据指标分析及可视化

2.1 财务数据处理

2.1.1 提取查账征收企业数据

在本次数据分析过程中，针对所给数据文件，本文使用 `pandas` 的 `read_csv()` 函数读取“LR.csv”文件，最终读取到的数据展示如下表 1 LR 原始数据表所示：

表 1 LR 表原始数据表

Stkcd	Accper	Typrep	B001100000	B001101000	Bbd1102000	Bbd1102101	Bbd1102203	B011103000	B011103101	...	B002300000	B002000000	B002000101
600696	2018-3-31	B	2.037196e+06	2.037196e+06	NaN	NaN	NaN	NaN	NaN	...	NaN	3.102472e+05	NaN
600696	2018-3-31	A	1.878459e+07	1.878459e+07	NaN	NaN	NaN	NaN	NaN	...	NaN	7.060818e+06	6730614.54
547	2018-3-31	B	3.023424e+05	3.023424e+05	NaN	NaN	NaN	NaN	NaN	...	NaN	-7.674035e+06	NaN
547	2018-3-31	A	5.179452e+08	5.179452e+08	NaN	NaN	NaN	NaN	NaN	...	NaN	8.492637e+07	79787795.49
2772	2018-3-31	B	4.432953e+07	4.432953e+07	NaN	NaN	NaN	NaN	NaN	...	NaN	2.317076e+07	NaN
...	...	...	...	...	...	...	...	...	...	...	...	...	...
600759	2019-1-1	A	3.326314e+09	3.326314e+09	NaN	NaN	NaN	NaN	NaN	...	NaN	2.064974e+08	69625085.41

在任务 1.1 中，分析发现表 1 数据存在大量的字段，应题目要求需要提取的是字段“Typerp”值为 A 的数据，此处字段“Typerp”即为“报表类型”。进一步地，全面考虑到税务机关有关企业所得税的征收方式，分为 A 类（查账征收的企业）和 B 类（核定征收的企业），最后使用“==”运算符筛选出字段“Typrep”值为“A”的数据，将筛选出的数据展示如下表 2 查账征收企业数据表所示：

表 2 查账征收企业数据表

Stkcd	Accper	Typrep	B001000000	B001100000	B001101000	B001200000	B001201000	B001207000	B001209000	B001210000
600696	2018-3-31	A	8.669264e+06	1.878459e+07	1.878459e+07	1.068992e+07	7.810739e+06	2.045951e+05	2.815107e+05	2.260219e+06
547	2018-3-31	A	9.675773e+07	5.179452e+08	5.179452e+08	4.266916e+08	2.729517e+08	7.893870e+05	1.265716e+07	1.344988e+08
2772	2018-3-31	A	8.953362e+07	2.671617e+08	2.671617e+08	1.898233e+08	1.527985e+08	6.940502e+05	3.013340e+07	9.984417e+06
2536	2018-3-31	A	8.198170e+07	6.967182e+08	6.967182e+08	6.147475e+08	5.005676e+08	6.804022e+06	1.680026e+07	8.143943e+07
818	2018-3-31	A	1.741463e+08	9.075395e+08	9.075395e+08	7.338691e+08	6.535983e+08	1.533694e+07	2.484191e+07	3.475893e+07

综上，将表 2 查账征收企业数据表以“utf-8”格式导出至“LR_1”。同时通过 pandas 中的 shape 属性查看筛选后的数据行数、列数如下图 1 所示：

1	df.shape
(33414, 15)	

图 1 筛选后的数据行数、列数图

如上图所示：最终得到，筛选出来的数据存在 33414 行，字段存在 15 列。

2.1.2 读取“LR_1.csv”、“ZCFZ.csv”、“Stk_ind.csv”并按要求合并

读取“LR_1.csv”、“ZCFZ.csv”两给数据文件，使用 merge () 函数根据要求提取“ZCFZ.csv”文件中的“A002000000”字段和“A001000000”字段合并到“LR_1.csv”数据中，合并后的数据如下表 3 “LR_1-ZCFZ”合并表所示：

表 3 “LR_1-ZCFZ”合并表

B001207000	B001209000	B001210000	B001211000	B001212000	B001303000	B002300000	A002000000	A001000000
2.045951e+05	2.815107e+05	2.260219e+06	1.154311e+05	1.742760e+04	NaN	NaN	4.437834e+08	7.455484e+08
7.893870e+05	1.265716e+07	1.344988e+08	2.518201e+06	3.276349e+06	NaN	NaN	1.681114e+09	7.442314e+09
6.940502e+05	3.013340e+07	9.984417e+06	-3.692930e+06	-9.415898e+04	NaN	NaN	1.422487e+09	4.176132e+09
6.804022e+06	1.680026e+07	8.143943e+07	9.136203e+06	NaN	NaN	NaN	1.156527e+09	3.292607e+09
1.533694e+07	2.484191e+07	3.475893e+07	3.701614e+06	1.631376e+06	NaN	NaN	1.322972e+09	4.061964e+09
...	...	...	...	...	...	...	...	...

接着读取“Stk_ind.csv”数据，根据刚才读取到的“LR_1.csv”文件中的“Stkcd”字段，提取“Stk_ind.csv”文件中字段为“Indnme”字段和“Nindnme”字段合并到“LR_1.csv”数据中,合并后的数据如下表 4 “LR_1-Stk_ind”合并表所示：

表 4 “LR_1-Stk_ind”合并表

B001209000	B001210000	B001211000	B001212000	B001303000	B002300000	A002000000	A001000000	Indnme	Nindnme
2.815107e+05	2.260219e+06	115431.05	17427.60	NaN	NaN	4.437834e+08	7.455484e+08	房地产	房地产业
7.317708e+05	5.451661e+06	-85335.43	462396.92	NaN	NaN	4.225418e+08	7.315552e+08	房地产	房地产业
1.360122e+06	1.072213e+07	-158480.03	566996.63	NaN	NaN	3.736597e+08	6.904487e+08	房地产	房地产业
1.707091e+06	1.275303e+07	277489.69	572593.44	NaN	NaN	5.184752e+08	8.130496e+08	房地产	房地产业
2.239964e+06	1.410068e+07	-180383.02	612730.86	NaN	NaN	9.913578e+07	4.144103e+08	房地产	房地产业
...	...	...	...	...	...	...	...	...	...

将三个数据表按要求提取合并后，导出为“LR_2.csv”文件，查看提取合并后的数据行数、列数如下图 2 所示：

result1_2.shape
(33414, 19)

图 2 取合并后的数据行数、列数图

最终得到，筛选出来的数据存在 33414 行，字段存在 19 列。

2.1.3 删除空值占比≥70%是数据列

读取“LR_2.csv”,考虑到数据量比较大，因此使用 python 中的 pandas 对数据进行初步的描述性统计分析。使用 pandas 中的 info 函数进行缺失值计数，最终统计得到的数据如图 3 缺失值统计图所示：

#	Column	Non-Null Count	Dtype
0	Stkcd	33414 non-null	int64
1	Accper	33414 non-null	object
2	Typrep	33414 non-null	object
3	B001000000	33414 non-null	float64
4	B001100000	33395 non-null	float64
5	B001101000	32709 non-null	float64
6	B001200000	33414 non-null	float64
7	B001201000	32686 non-null	float64
8	B001207000	33388 non-null	float64
9	B001209000	32018 non-null	float64
10	B001210000	32724 non-null	float64
11	B001211000	32732 non-null	float64
12	B001212000	32183 non-null	float64
13	B001303000	1202 non-null	float64
14	B002300000	3 non-null	float64
15	A002000000	33414 non-null	float64
16	A001000000	33414 non-null	float64
17	Indnme	33414 non-null	object
18	Nindnme	33414 non-null	object

dtypes: float64(14), int64(1), object(4)
memory usage: 4.8+ MB

图 3 缺失值统计图

如上图所示，“LR_2.csv”数据表中字段“B001303000”与“B002300000”明显存在大量的缺失值且为非重要字段。通过使用 isnull () 函数和 sum () 函数计算出每列的空值占比，满足题目要求占比达 70%及以上的数据字段，故做删除处理。最后将处理后的数据导出为“LR_3.csv”文件。

```
result1_3.shape[1]
```

17

图 4 删除空值后的行数图

最终得到，做删除处理后的数据存在 17 列。

2.1.4 空值处理

在完成上述处理之后，读取数据“LR_3.csv”，首先使用 pandas 中的 isna()函数检查每个字段中空值，其次使用 pandas 中的 sum()统计出空值的个数，最终统计得到的数据结果如下图 5 空值统计结果图所示：

```

: data.isna().sum()
: Stkcd      0
  Accper     0
  Typrep     0
  B001000000 0
  B001100000 19
  B001101000 705
  B001200000 0
  B001201000 728
  B001207000 26
  B001209000 1396
  B001210000 690
  B001211000 682
  B001212000 1231
  A002000000 0
  A001000000 0
  Indrme     0
  Nindrme    0

```

图 5 空值统计结果图

使用 pandas 中的 `dropna()` 函数将上诉统计为空值的字段的相应行删除，导出为“LR_4.csv”文件且该文件编码设置为 UTF-8。最终得到，做空值处理后的数据存在 30888 行，如图 6 所示。

```

result1_4.shape[0]
30888

```

图 6 空值处理后的数据行数图

2.1.5 时间格式规范化

在读取“LR_4.csv”时，由下表 5 “LR_4.csv”数据表很明显的能看出“Accper”字段的时间格式为“YYYY-m-dd”格式类型。

表 5 “LR_4.csv”数据表

	Stkcd	Accper	Typrep	B001000000	B001100000	B001101000
0	600696	2018-3-31	A	8.669264e+06	1.878459e+07	1.878459e+07
1	600696	2018-6-30	A	1.726052e+07	6.630822e+07	6.630822e+07
2	600696	2018-9-30	A	2.688275e+07	4.136409e+08	4.136409e+08
3	600696	2018-1-1	A	2.015808e+07	1.750893e+08	1.750893e+08
4	600696	2018-12-31	A	2.561621e+07	1.100745e+09	1.100745e+09
...	...	...	...	...	...	...
30883	688100	2019-1-1	A	2.008493e+08	1.038641e+09	1.038641e+09

为了确保数据的严谨性和准确性，在此故做时间格式转化处理，使用 pandas 中的 `to_datetime()` 的函数对该字段的时间进行转换，转换结果为“YYYY-mm-dd”格式，转换后的结果如下图 7 时间转换结果图所示。

进一步的，使用 pandas 中的 `astype()` 函数将时间转换成字符串便于后续的使用，最终将数据导出为“LR_5.csv”。

```

0      2018-03-31
1      2018-06-30
2      2018-09-30
3      2018-01-01
4      2018-12-31
...
30883  2019-01-01
30884  2019-01-01
30885  2019-01-01
30886  2019-01-01
30887  2019-01-01

```

图 7 时间转换数据结果图

2.1.6 利润率与资产负债率的计算

2.1.6.1 利润率及资产负债率的说明

在本次数据分析过程中，为了便于理解，多方查阅得到的关于资产负债率和利润率的定义如下：

资产负债率：资产负债率作为静态指标，用于反映企业的资产中有多少是通过债务获取的，比如企业的财务风险。一个过高的资产负债率可能意味着企业过度依赖债务，这可能会增加违约的风险。而一个过低的资产负债率可能意味着企业没有充分利用债务的优势来扩大规模和提高盈利能力。

利润率：利润率是衡量企业盈利能力的重要指标，反映了企业的盈利能力。比如企业每销售一元商品或提供一元服务所获得的净利润。一个高的利润率可能意味着企业的盈利能力强，而一个低的利润率可能意味着企业的盈利能力弱。

2.1.6.2 计算对应的利润率和资产负债率

本文根据表 X 的计算公式，计算利润率和资产负债率。

表 6 指标计算公式

指标名称	计算方法
利润率	利润总额（B001000000）/营业总收入（B001100000）
资产负债率	负债合计（A002000000）/资产总计（A001000000）

本文针对利润率和资产负债率不在[-300%，300%]范围内的数据做异常值处理，删除所在的行。根据题目要求将数据导出为"LR_new.csv"文件。

```
1 result1_6.shape
(30690, 19)
```

图 8 "LR_new.csv"文件数据行数、列数展示图

如上图 8 所示，修改后的数据存在 30690 条数据行，19 个数据列。

2.1.6.3 绘制相关柱状图

最终根据题目要求提取出利润率为前五的企业的证券代码，并使用 matplotlib.pyplot 的 bar() 函数绘制柱状图，最终结果如下图 9 企业利润率图所示：




图 9 企业利润率图

同时提取出资产负债率为前五的企业的证券代码,使用同样的方法绘制柱状图,最终结果如下图 10 企业资产负债率图所示:



图 10 企业资产负债率图

3.财务数据指标分析及可视化

3.1 行业营业利润对比分析

根据题目要求生成柱状图,对“LR_new.csv”文件使用 pandas 中的 `pd.to_datetime()`函数,让时间有便于后续的时间操作分析。对筛选时间后的数据进行行业利润求和数据,如图 11 所示。




图 11 各行业利润图

根据上述的数据最终生成 2019 年 9 月个同行业大类的利润对比柱状图如图 12 所示:




图 12 2019 年 9 月个同行业大类的利润对比柱状图

可知房地产利润最高，远超其他

根据要求生成折线图表示业利润变化，首先需要根据要求对时间进行筛选
针对编程思想，部分重要代码示例如下：

```
data_ = data[(data['Accper'] >= '2018-01-01') & (data['Accper'] <= '2019-09-30')]
data_
```

将时间筛选后使用 `dt.to_period('Q')` 这个库将日期划分为季度，接着 `data_` 数据表中的 `Indnme` 和 `quarter` 两个列的值，对 `data_` 数据表进行分组，然后计算每个分组中的利润率列的平均值，并赋值给 `result2`

针对编程思想，部分重要代码示例如下：

```
result2 = data_.groupby(['Indnme', 'quarter'], as_index=False)['利润率'].mean()
result2
```

根据上述的清理之后的数据然后进行折线图可视化




图 13 行业利润变化图

在 2018 年 1 月至 2019 年 9 月期间，金融行业利润率均值稳定，在 2019 年第一季度达到了其利润率均值的峰值，前后季度表现出最大的增降幅。

2018 年第四季度时，利润率的平均值不稳定

3.2 行业与企业营收分析

根据题目要求可得如下图所示的行业大类的利润均值，而其中金融为行业利润均值第一。



图 14 行业大类利润均值图

细分金融行业不同细类 2019 年 9 月的利润率如图 15 行业大类利润率图所示，

```

Nindnme
证券、期货业    0.370759
其他金融业      0.162425
银行业          0.152000
保险业          0.020105
Name: 利润率, dtype: float64

```

图 15 行业大类利润率图

为了直观反应各细类的利润率，绘制出利润率排名前 3 细类的利润率柱状图如图 16 所示：



图 16 2019 年金融行业各细类利润率对比图

对于金融行业的证券、期货业 2019 年 9 月利润率排序如表 7 基于 Stkcd 排列的利润率表所示：

表 7 基于 Stkcd 排列的利润率表

Stkcd	利润率
300059	0.535592
600783	0.527919
600864	0.502979
600155	0.376119
300309	0.347491

根据上表数据绘制如图 17 的证券、期货业排名前 5 的企业利润率柱状图（注：将该细类利润率排名第 1 的企业记为“T1”）。



图 17 证券、期货业 9 月利润率 Top5 柱状图

由图 18 可得企业代码为 300059 的企业利润率最高,进而分出该企业的营业成本、营业税金及附加、销售费用、管理费用、财务费用。得出对应的饼图,




图 18 2019 年企业“T1” 营业总成本分析饼图

由图 19 可得出该企业的管理成本占大多数所以该企业正在投入大量的资源来维持其非生产性的运作,如管理人员的工资、办公费用、研究开发部门的费用等。其次,这也可能表明企业对内部管理和决策制定的关注度较高。

根据企业“T1”2019 年 3 月、6 月、9 月三个季度营业总收入、营业总成本数据可绘制出 2019 年企业“T1”经营情况分析的柱状图与利润率、资产负债率变化的折线图的组合图如图 19 所示。




图 19 2019 年企业“T1”经营情况分析柱状图

根据上图可知，企业“T1”在九月的营业总收入和营业总成本达到最大，分别为 3096764842 和 1669571594，同时，在第三个季度的利润率达到最大，资产负债率达到最小。

说明“T1”在九月份较受人们喜爱，企业在该类投入成本随之增大，相应地，利润也增加，因此建议企业考虑继续投资和优化这些活动，以吸引更多潜在客户，同时刺激 3-6 月份消费者的消费。

3.3 可视化大屏

应题目要求进行可采取 tableau 工具进行大屏可视化：




图 20 可视化大屏分析图

- (1) 总销售额: 显示了 2019 年 5 月的总销售额为 1.25 亿, 较上月增长了 8.7%, 较去年同期增长了 15.3%。

- (2) 销售额排名：显示了 2019 年 5 月各地区的销售额排名，其中华东地区排名第一，销售额为 3,987 万，占总销售额的 31.9%，较上月增长了 9.4%，较去年同期增长了 18.2%。
- (3) 销售额趋势：显示了 2018 年 1 月至 2019 年 5 月各月份的销售额变化，可以看出销售额呈现出波动的上升趋势，其中 2019 年 1 月和 2019 年 5 月的销售额达到了峰值，分别为 1.28 亿和 1.25 亿。
- (4) 销售额构成：显示了 2019 年 5 月各产品类别的销售额占比，其中家电类别占比最高，为 38.6%，销售额为 4,823 万，较上月增长了 7.8%，较去年同期增长了 16.4%。

4.企业利润预测及财务造假识别

4.1 各个指标与利润总额的相关性分析

根据题目要求读取数据之后为了方便选择修改列名

```
df.columns = ['证券代码','截止日期','流动比率','利息保障倍数','资产负债率','存货周转率','\
'资产报酬率','存货占流动资产比','长期资本收益率','营业毛利率','应税率','\
'应收账款周转率','营业收入','营业成本','营业税金及附加','\
'业务费用','资产减值损失','利润总额','造假']
df
```

图 21 修改的列名图

检验数据是否有空值使用 df.info()

0	证券代码	10994 non-null	int64
1	截止日期	10994 non-null	int64
2	流动比率	10994 non-null	float64
3	利息保障倍数	10994 non-null	float64
4	资产负债率	10994 non-null	float64
5	存货周转率	10994 non-null	float64
6	资产报酬率	10994 non-null	float64
7	存货占流动资产比	10994 non-null	float64
8	长期资本收益率	10994 non-null	float64
9	营业毛利率	10994 non-null	float64
10	应税率	10994 non-null	float64
11	应收账款周转率	10994 non-null	float64
12	营业收入	10994 non-null	float64
13	营业成本	10994 non-null	float64
14	营业税金及附加	10994 non-null	float64
15	业务费用	10994 non-null	float64
16	资产减值损失	10994 non-null	float64
17	利润总额	10994 non-null	float64
18	造假	10994 non-null	int64

图 22 空值判定图

确定没有空值之后，选择在各个列与"利润总额"列之间的相关系数，并按照相关系数的大小进行降序排列

利润总额	1.000000
营业收入	0.782726
业务费用	0.772832
营业成本	0.737736
营业税金及附加	0.565440
资产减值损失	0.238524
资产报酬率	0.043744
截止日期	0.039733
存货周转率	0.037973
利息保障倍数	0.017442
长期资本收益率	0.009256
应税率	0.005212
营业毛利率	0.000117
资产负债率	-0.001783
证券代码	-0.003595
造假	-0.014340
流动比率	-0.026885
存货占流动资产比	-0.046778
应收账款周转率	-0.084372
Name: 利润总额, dtype: float64	

图 23 相关系数排序图

根据任务要求相关度最高的五个指标排序柱状图如下




图 24 与利润总额相关性最大的五个指标柱状图

根据这个图能清晰的看见“营业收入”、“业务费用”、“营业成本”三个指标与利润的相关性较高，作为判断企业利润的最终指标。

4.2 企业利润预测模型的建立

对于已有的指标进行特性性分析，如下图 25 所示




图 25 特征分析图

通过分析上图各字段数据的特征可以发现，所有字段特征均趋近于正态分布，并且分布集中。这意味着大部分的数据都接近平均值，而很少有极端值或异常值对于模型的影响较小。

本次实验模型使用线性回归、决策树、随机森林、梯度提升数、XGBOOST、LIGHTGBM 模型进行利润总额回归预测五折交叉验证并进行网格搜索调参可知后 R2 如下，R-squared（R2）是用于评估回归模型拟合优度的一种统计度量。它表示模型解释因变量方差的比例。R2 的取值范围在 0 到 1 之间，越接近 1 表示模型对观察数据的拟合越好。 如下图 26 所示，

```
开始训练模型: Liner
Liner预测的准确率为:0.9291843214075708%
开始训练模型: DecisionTree
DecisionTree预测的准确率为:0.7787953045207984%
开始训练模型: RandomForest
RandomForest预测的准确率为:0.8229750313656384%
开始训练模型: GradientBoost
GradientBoost预测的准确率为:0.8724360207183558%
开始训练模型: XGBoost
XGBoost预测的准确率为:0.7187040066134658%
开始训练模型: lightgbm
[LightGBM] [Info] Auto-choosing col-wise multi-threading, the overhead of testing was 0.000135 seconds.
You can set `force_col_wise=true` to remove the overhead.
[LightGBM] [Info] Total Bins 1275
[LightGBM] [Info] Number of data points in the train set: 8795, number of used features: 5
[LightGBM] [Info] Start training from score 342546612.061991
lightgbm预测的准确率为:0.6686258699461114%
```

图 26 各模型精度图

由模型的构建可知，本次实验的数据对于多元线性回归模型上的表现较好，所以后续实验将基于该模型进行构建。

对于测试数据“test.csv”进行数据探索如下图 27 所示，

```

1 test_src.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10928 entries, 0 to 10927
Data columns (total 6 columns):
#   Column          Non-Null Count  Dtype
---  -
0   TICKER_SYMBOL    10 non-null     float64
1   YYSR             10 non-null     float64
2   YWYF             10 non-null     float64
3   YYCB             10 non-null     float64
4   YYSJJFJ          10 non-null     float64
5   ZCJZSS           10 non-null     float64
dtypes: float64(6)

```

图 27 测试集数据探索图

去除无用指标"TICKER_SYMBOL"同时利用建立的多元线性回归模型进行模型的预测，如下表 8 所示，

表 8 企业利润预测表

TICKER_SYMBOL	LRZE
4953174.00	20988380663850733568.00
4961537.00	39215991722109165568.00
4962538.00	7935264779266719744.00
4968740.00	6105393820419825664.00
4973917.00	4353305614488545280.00
4978589.00	27146488772393140224.00
4978721.00	6012364160926507008.00
4986535.00	6815957438584830976.00
4990739.00	11989319296026580992.00
4990942.00	7418663038007464960.00

4.3 涉嫌财务造假企业的判断

通过读取给定数据“financial_data.csv”判断该数据中字段“FLAG”值的占比可视化如图 28 所示，




图 28 字段“FLAG”值的占比饼图

由图示可知，该字段中的 0 与 1 值的分布严重不平衡，数据中财务未造假的数据占据绝大部分，所以会对后续模型性能有影响。

通过分析字段“FLAG”相关性从而得出关键影响因子的指标，如图 29 所示




图 29 字段“FLAG”相关性分析图

通过图示分析，本文筛选出“YSZKZZL”、“ZCBCL”、“ZCFZL”、“CHZZL”等字段对“FLAG”进行分析。

本文进行标准后等处理后，使用线性回归、决策树、支持向量机、随机森林、xgboost、lightgbm、CatBoost 模型进行训练以及验证，其中 catboost 模型的效果最好，采用该模型作为最终模型进行预测。使用该模型对验证集进行预测，对预测结果打印分类报告以展示精确率、召回率、f1-score 等指标。其中表现最好的是 CatBoostClassifier 模型，如图 30 所示。

```
CatBoostClassifier
准确率: 1.0
f1: 1.0
召回率: 1.0
精确率: 1.0
```

图 30 模型精度图

同时通过绘制该模型的 ROC 曲线如图 31 所示：




图 31 CatBoostClassifier 模型的 ROC 曲线图

由图 32 CatBoostClassifier 模型的 ROC 曲线图可得，该模型在本次实验上的数据表现较好且无过拟合现象存在。

通过读取“financial_data_new.csv”文件并进行跟以上训练集数据相同的处理后并对相关字段进行筛选，并通过训练好的 CatBoostClassifier 模型进行预测，结果如表 33 涉嫌财务造假企业预测结果表所示：

表 9 涉嫌财务造假企业预测结果表

TICKER_SYMBOL	pred_FLAG
4992858	0
4993201	0
4998808	0
4897311	1
4999709	0

由上图模型预测出的数据分析可得，证券代码为“4897311”的企业，极大置信涉嫌财务造假。

5.参考文献

- [1] 常乐.基于 GONE 理论的 Y 企业财务舞弊动因与防范研究[D].延安大学,2023.
- [2] 龙珍.长园集团并购和鹰科技的财务舞弊动因、识别与防范对策研究[D].景德镇陶瓷大学,2023.
- [3] 郭青妮.我国上市公司财务造假识别模型研究[D].中央财经大学,2022.
- [4] 吕格致.基于财务异常信号的财务欺诈识别分析[D].三峡大学,2022.